



Variáveis aleatórias, distribuições e incerteza

Modelagem e Simulação - Aula #05


Prof. Dr. Carlos Melo

 carlos.melo@upe.br

Assimetria e Curtose

- A assimetria indica para qual lado se estende a cauda da distribuição
 - **Negativa:** a cauda vai para a esquerda;
 - **Próximo de zero:** implica em distribuição simétrica;
 - **Positiva:** a cauda vai para a direita.
- Já a Curtose ajuda na avaliação do peso das caudas e a ocorrência de *outliers*
 - **< 0** implica caudas mais leves que a normal;
 - **≈ 0** caudas semelhantes às da normal;
 - **> 0** caudas mais pesadas que as da normal.
- Distribuições simétricas podem apresentar comportamentos diferentes nos extremos.

Assimetria e Curtose




Outliers

- Um *outlier* é uma observação que se afasta significativamente do padrão da amostra.
- Um critério comum para caracterizar um *outlier* utiliza o intervalo interquartil (**IIQ**):
 - **IIQ** = $Q_3 - Q_1$
 - **LI** = $Q_1 - 1,5 \times \text{IIQ}$
 - **LS** = $Q_3 + 1,5 \times \text{IIQ}$
- Valores abaixo de **LI** (Limite Inferior) ou acima de **LS** (Limite Superior) são considerados candidatos a *outliers*.
- Um *outlier* pode representar:
 - Erro de medição ou registro;
 - Evento raro, mas real;
 - Mudanças no comportamento do sistema;
 - Mistura de diferentes populações.

Outliers

- $IIQ = 40 - 20 = 20$
- $LI = 20 - 1,5 \times (20) = -10$
- $LS = 40 + 1,5 \times (20) = 70$

Boxplot e identificação de candidatos a outliers



Descrever a amostra não descreve o processo

- A **análise** exploratória descreve os dados que foram observados:
 - Valores típicos e extremos;
 - Variabilidade e forma;
 - Relações.
- Enquanto que um **modelo** probabilístico pode produzir:
 - Quais resultados são possíveis;
 - Com que probabilidade podem ocorrer;
 - Como uma métrica varia entre repetições;
 - Qual é a chance de ultrapassar um limite.
- A amostra é uma realização do processo enquanto o modelo tenta representá-lo
 - Dados observados → Modelo Probabilístico → Análise e Simulação

Experimento Aleatório

- Em um experimento aleatório conhecemos as possibilidades não o próximo resultado
- Considere um teste realizado em quatro servidores.
- Ao final, cada servidor pode estar:
 - **U**: operante (**up**);
 - **D**: indisponível (**down**)
- Um possível resultado é:
 - $\omega = (U, D, U, U)$
- O conjunto de todos os resultados possíveis é o espaço amostral:
 - $\Omega = \{U, D\}^4$
- Um evento é um conjunto de resultados de interesse
 - $A = \{\text{pelo menos um servidor está indisponível}\}$
- Antes do teste conhecemos Ω , mas não sabemos qual ω será observado.

Variável aleatória

- Uma variável aleatória resume o resultado de um experimento em um valor
- No teste realizado, considere:
 - $\mathbf{X}$ = número de servidores indisponíveis
- Formalmente, a variável aleatória é uma função:
 - $X : \Omega \rightarrow \mathbb{R}$
- Ele associa cada resultado do experimento a um número:
 - $X(U, D, U, U) = X(U, U, D, U) = 1$ *#Resultados diferentes, mesmo valor*
 - $X(D, U, D, U) = 2$
 - $X(D, D, D, D) = 4$
- A função não é aleatória o que é aleatório é o resultado do experimento sobre o qual ela é aplicada.

Variáveis aleatórias discretas e contínuas

Variável aleatória discreta	Variável aleatória contínua
Assume valores de um conjunto enumerável	Pode assumir qualquer valor de um intervalo
Resulta frequentemente de uma contagem	Resulta frequentemente de uma medição
Número de falhas	Tempo até uma falha
Pessoas em uma fila	Tempo de espera
Requisições concluídas	Tempo de resposta
Pacotes perdidos	Utilização de um recurso

- Número de servidores indisponíveis
 - $X \in \{0, 1, 2, 3, 4\}$
- Tempo necessário para reparar um servidor
 - $T \in \mathbb{R}^+$


Variável aleatória discreta

- Em uma variável discreta, cada valor recebe uma probabilidade
- Considere
 - X = número de servidores indisponíveis
 - Cada servidor tenha probabilidade 0,10 de estar indisponível
 - Os estados dos servidores sejam independentes
- A função massa de probabilidade associa cada valor de X à sua probabilidade:
 - $p_X(x) = P(X = x)$
- Essa função de probabilidade deve satisfazer:
 - $0 \leq p_X(x) \leq 1$
 - $p_X(0) + p_X(1) + p_X(2) + p_X(3) + p_X(4) = 1$
 - $0,6561 + 0,2916 + 0,0486 + 0,0036 + 0,0001 = 1$

$$\sum_{x=0}^4 p_X(x) = 1 \qquad \sum_{x \in X} p_X(x) = 1$$

Cada valor recebe uma probabilidade

Distribuição do número de servidores indisponíveis



<i>x</i>	$P(X = x)$
0	0,6561
1	0,2916
2	0,0486
3	0,0036
4	0,0001


Variável aleatória contínua

- Em uma variável aleatória contínua, a probabilidade é representada por uma área
- Considere:
 - $T = \text{tempo necessário para concluir um atendimento}$
- A função densidade de probabilidade é representada por:
 - $f_T(t)$
- A probabilidade de T estar entre dois valores corresponde à área sob a curva:

- $$P(a \leq T \leq b) = \int_a^b f_T(t) dt$$

- Para uma variável contínua:
 - $P(T = t) = 0$
- A altura da curva é uma densidade enquanto a área representa a probabilidade.

Variável aleatória contínua




Função de distribuição acumulada

- A função de distribuição acumulada informa a probabilidade de a variável assumir um valor menor ou igual a x :
 - $FX(x) = P(X \leq x)$
- Ela pode ser utilizada com variáveis aleatórias discretas e contínuas
- Exemplo discreto:
 - $P(X \leq 1) = P(X = 0) + P(X = 1)$
 - $P(X \leq 1) = 0,6561 + 0,2916 = 0,9477$
- Exemplo contínuo:
 - $F_T(2) = P(T \leq 2)$
 - $P(T > 2) = 1 - F_T(2)$
 - Se $F_T(2) = 0,95$ então $P(T > 2) = 1 - 0,95 = 0,05$
- Probabilidade acima de um limite
 - $P(X > x) = 1 - FX(x)$
- A função acumulada transforma limites de interesse em probabilidades.

Função de distribuição acumulada

Funções de distribuição acumulada

Começam em 0, nunca diminuem e alcançam ou se aproximam de 1



A variância diz quanto os resultados se afastam do esperado

- A variância representa o afastamento quadrático médio em relação ao valor esperado:
 - $Var(X) = E[(X - \mu_X)^2]$
- O desvio padrão retorna à unidade original da variável:
 - $\sigma_X = \sqrt{Var(X)}$
- Para os quatro servidores:
 - $\mu_X = 0,4$
 - $Var(X) = 0,36$
 - $\sigma_X = 0,6$
- Valor esperado e variabilidade devem ser analisados em conjunto.

Estatísticas da amostra estimam parâmetros do modelo


- A amostra fornece estimativas:
 - $\bar{x}$ estima μ
 - s^2 estima σ^2

Dados observados	Modelo probabilístico
Média amostra $\bar{x}$	Valor esperado μ
Variância amostral s^2	Variância σ^2
Desvio padrão amostral s	Desvio padrão σ
ECDF	CDF $F_X(x)$

Estatísticas da amostra estimam parâmetros do modelo

Estatísticas amostrais estimam parâmetros do processo

Um mesmo processo gera diferentes amostras



As médias $\bar{x}_1$, $\bar{x}_2$ e $\bar{x}_3$ variam, mas todas procuram estimar o mesmo parâmetro μ .

Bernoulli: uma única tentativa e dois resultados possíveis

- Considere uma única tentativa:

$$Y = \begin{cases} 1, & \text{evento ocorrer} \\ 0, & \text{caso contrario} \end{cases}$$

- A variável Y segue uma distribuição de Bernoulli se:


- $P(Y = 1) = p$
- $P(Y = 0) = 1-p$

- Seus principais parâmetros são:

- $E[Y] = p$
- $Var(Y) = p(1-p)$


- Exemplos:

- Uma requisição termina dentro do prazo;
- Um servidor falha durante um teste;
- Um equipamento está disponível no instante observado;
- Um usuário conclui uma tarefa.



Binomial: Conta ocorrências em várias tentativas

- Considere n tentativas de Bernoulli independentes, todas com a mesma probabilidade p :
 - $X = Y_1 + Y_2 + \dots + Y_n$
- Então: $X \sim \text{Bin}(n, p)$
- A probabilidade de observar exatamente k ocorrências é:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$


A blue arrow points from the binomial coefficient $\binom{n}{k}$ to the first bullet point below. A purple arrow points from the term $p^k (1 - p)^{n-k}$ to the second bullet point below.

- Número de maneiras de posicionar as k ocorrências
- Probabilidade de uma dessas combinações
- Os principais parâmetros são:
 - $E[X] = np$
 - $\text{Var}(X) = np(1-p)$

Poisson: eventos ocorridos durante um intervalo

- Considere:
 - $N(t)$ = número de eventos observados durante um intervalo t
- Se os eventos ocorrem com taxa média λ , podemos representar:
 - $N(t) \sim \text{Poisson}(\lambda t)$
- A probabilidade de ocorrerem exatamente k eventos é:

$$P(N(t) = k) = \frac{e^{-\lambda t} (\lambda t)^k}{k!}, k = 0, 1, 2, \dots$$

- Seus principais parâmetros são:
 - $E[N(t)] = \lambda t$
 - $\text{Var}(N(t)) = \lambda t$
- Onde:
 - λ : taxa média de ocorrência;
 - t : duração do intervalo;
 - k : número de eventos;
 - $k!$: fatorial de k ;
 - e : número de Euler

Poisson: eventos ocorridos durante um intervalo


- Se chegam, em média, três requisições por minuto, então $\lambda = 3$ req/min
 - A probabilidade de nenhuma requisição chegar durante um minuto é:

$$P(N(1) = 0) = \frac{e^{-3}(3)^0}{0!} \approx 0,0498$$

- Já para em um minuto:

exatamente

Distribuição de Poisson para $\lambda t = 3$



Exponencial: representa tempos entre eventos

- Considere:
 - T = tempo até a próxima ocorrência
- Se T segue uma distribuição exponencial, então:
 - $T \sim \text{Exp}(\lambda)$
- Sua função densidade é:

$$f_T(t) = \lambda e^{-\lambda t}, t \geq 0$$

- Já a distribuição acumulada é:

$$F_T(t) = P(T \leq t) = 1 - e^{-\lambda t}$$


- A probabilidade de o tempo ultrapassar t é:

$$P(T > t) = e^{-\lambda t}$$

Exponencial: representa tempos entre eventos

- Seus principais parâmetros são:

$$E[T] = \frac{1}{\lambda} \quad \text{Var}[T] = \frac{1}{\lambda^2} \quad \sigma_T = \frac{1}{\lambda}$$



Poisson e Exponencial observam o mesmo processo de duas maneiras

- Considere eventos que ocorrem com taxa constante λ .
 - Quantos eventos ocorrem durante t ? (Poisson)
 - Quanto tempo transcorre entre eventos? (Exponencial)
- Para uma taxa de três chegadas por minuto:
 - $E[N(1)] = 3$ (Poisson)
 - $E[T] = \frac{1}{3}$ minuto = 20 segundos (Exponencial)
- Contagem e duração são duas perspectivas do mesmo processo de chegadas.

Contagem de eventos e tempo entre chegadas

Visão 1: contar eventos no intervalo




Visão 2: medir o tempo entre eventos

Exponencial não considera o tempo já transcorrido

- Para $T \sim \text{Exp}(\lambda)$:
 - $P(T > s + t \mid T > s) = P(T > t)$
- Essa é a propriedade de ausência de memória:
 - Sabemos que o evento ainda não ocorreu após s unidades de tempo, mesmo assim, a distribuição do tempo adicional de espera é igual à distribuição considerada no início.
 - O modelo “não envelhece” uma vez que o tempo já transcorrido não altera a taxa do próximo evento.
- Exemplo:
 - Se o tempo médio entre chegadas é de 20 segundos e nenhuma chegada ocorreu nos primeiros 10 segundos, o tempo médio adicional continua sendo 20 segundos.

Exponencial não considera o tempo já transcorrido

Ausência de memória da distribuição exponencial



Normal: representa variações simétricas em torno da média


- Uma variável normal é representada por:
 - $X \sim \mathcal{N}(\mu, \sigma^2)$
- Sua função densidade é:

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- Onde:
 - μ : média e centro da distribuição;
 - σ : desvio padrão;
 - σ^2 : variância.

Normal: representa variações simétricas em torno da média

- A distribuição normal é:
 - Contínua;
 - Simétrica;
 - Definida para $-\infty < x < +\infty$;
 - Caracterizada completamente por μ e σ .
- Regra aproximada:
 - $P(\mu - \sigma \leq X \leq \mu + \sigma) \approx 68\%$
 - $P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 95\%$
 - $P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 99,7\%$



Natureza da variável aleatória determina a distribuição

Pergunta	Distribuição candidata	Principais condições
Um evento ocorreu ou não?	Bernoulli	1 tentativa e 2 resultados
Quantas ocorrências em n tentativas?	Binomial	n fixo, mesma p e independência
Quanto eventos ocorreram durante t ?	Poisson	Taxa constante e incrementos independentes
Quanto tempo até o próximo evento?	Exponencial	Taxa constante e ausência de memória
Como uma medida varia simetricamente?	Normal	Simetria e efeitos agregados

Natureza da variável aleatória determina a distribuição

A natureza da variável orienta a escolha da distribuição



A distribuição é uma candidata: suas hipóteses ainda precisam ser verificadas.

Ajustar uma distribuição exige estimar seus parâmetros

- Um parâmetro desconhecido é representado por θ
- Sua estimativa calculada a partir da amostra é representada por $\hat{\theta}$
- Onde:
 - r : número de ocorrências;
 - n : número de tentativas;
 - $\overline{N}$: média das contagens;
 - $\overline{t}$: duração de cada intervalo;
 - $\overline{T}$: média dos tempos observados.

Distribuição	Parâmetro	Estimativa
Bernoulli ou Binomial	Probabilidade p	$\hat{p} = \frac{r}{n}$
Poisson	Taxa λ	$\hat{\lambda} = \frac{\overline{N}}{t}$
Exponencial	Taxa λ	$\hat{\lambda} = \frac{1}{\overline{T}}$
Normal	Média μ	$\hat{\mu} = \overline{x}$
Normal	Desvio padrão σ	$\hat{\sigma} = s$

Parâmetros plausíveis não garantem um bom ajuste

- O ajuste deve comparar os dados observados com o modelo proposto.
- Comparações gráficas
 - Histograma ou densidade empírica versus PDF;
 - ECDF versus CDF;
 - Quantis observados versus quantis teóricos;
 - Comportamento das caudas.



Parâmetros plausíveis não garantem um bom ajuste

- Verificações numéricas
 - Teste qui-quadrado para variáveis discretas;
 - Testes de Kolmogorov–Smirnov ou Anderson–Darling para variáveis contínuas;
 - Diferença entre estatísticas observadas e previstas.
- Hipóteses do processo
 - Observações independentes;
 - Processo estável;
 - Parâmetros aproximadamente constantes;
 - Domínio compatível com a variável.

Parâmetros plausíveis não garantem um bom ajuste

Comparação entre os dados e uma distribuição candidata

A média e o desvio padrão podem ser plausíveis mesmo quando a forma não está bem representada



A média amostral também é uma variável aleatória

- Considere uma amostra com n observações:

- $X_1, X_2, \dots, X_n$

- A média amostral é:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- Como a amostra muda, $\bar{X}$ também muda.
- Se as observações são independentes:

$$E[\bar{X}] = \mu \quad SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$


- Quando σ é desconhecido:

$$\widehat{SE}(\bar{X}) = \frac{s}{\sqrt{n}}$$

- Onde SE é o erro padrão que descreve a variabilidade da média, uma vez que o desvio padrão descreve as observações da amostra.


A média amostral também é uma variável aleatória

A média amostral varia menos que as observações individuais




Intervalo de confiança e a precisão da estimativa

- Um intervalo de confiança para a média possui a forma:
- $\text{estimativa} \pm \text{valor crítico} \times \text{erro padrão}$
 - Ou $\bar{x} \pm c \frac{s}{\sqrt{n}}$
 - Onde:
 - $\bar{x}$: média da amostra observada;
 - c : valor crítico;
 - s : desvio padrão amostral;
 - n : tamanho da amostra.
- Para confiança de 95%:
 - $1 - \alpha = 0,95 \rightarrow \alpha = 0,05$



O desvio-padrão define qual referência usar

- Queremos construir um intervalo para a média da população:
 - μ
- A escolha do método depende do que sabemos sobre o desvio-padrão populacional:
 - Se o σ é conhecido a referência utilizada é a normal padronizada Z
 - Se o σ é desconhecido usamos a distribuição t de Student
- Na prática, σ quase nunca é conhecido. Por isso, geralmente utilizamos o desvio-padrão da amostra:
 - s
- Condições importantes:
 - Observações independentes;
 - População aproximadamente normal quando a amostra é pequena;
 - Ausência de assimetrias ou valores extremos muito severos.



A distribuição t incorpora a incerteza sobre o desvio-padrão

- Quando σ é desconhecido, o intervalo de confiança para a média é:
 - $\bar{x} \pm t^* \frac{s}{\sqrt{n}}$
- em que:
 - $\bar{x}$: média observada na amostra;
 - s : desvio-padrão da amostra;
 - n : tamanho da amostra;
 - $\frac{s}{\sqrt{n}}$: erro-padrão da média;
 - t^* : valor crítico da distribuição t ;
 - $n-1$: graus de liberdade.
- Para confiança de 95%:
 - $\alpha = 1 - 0,95 = 0,05$
 - $t^* = t_{1-\alpha/2, n-1}$
- O valor t^* é positivo e deixa 2,5% em cada cauda.

Construindo intervalo de confiança

- Considere uma amostra com:
 - $\bar{x} = 119,28$ transações/s
- Para 95% de confiança e 99 graus de liberdade $t^* = 1,9842$
- Erro padrão

$$SE = \frac{s}{\sqrt{n}} = \frac{29,23}{\sqrt{100}} = 2,923$$

- Margem de erro
 - $ME = t^* \times SE = 1,9842 \times 2,923 \approx 5,80$
- Intervalo de confiança
 - $IC_{95\%} = [113,48; 125,08]$ transações/s

Mais precisão exige amostras maiores

- A margem de erro para a média é aproximadamente:

$$\varepsilon = z^* \frac{\sigma}{\sqrt{n}}$$

- Isolando n :

$$n \geq \left(\frac{z^* \sigma}{\varepsilon} \right)^2$$

- Considere:
 - $\sigma = 30$ transações/s
 - $\varepsilon = 8$ transações/s

Para 95% de confiança: $z^* = 1,96$

Logo: $n \geq ((1,96 * 30)/8)^2 = 54,02$

Como o tamanho da amostra deve ser inteiro, então: $n = 55$

Calculando o intervalo de confiança em Python

```
import numpy as np
from scipy.stats import t

media_amostral = 119.28
desvio_amostral = 29.23
n = 100
confianca = 0.95

alpha = 1 - confianca
graus_liberdade = n - 1

erro_padrao = desvio_amostral / np.sqrt(n)

t_critico = t.ppf(
    1 - alpha / 2,
    df=graus_liberdade
)

margem_erro = t_critico * erro_padrao

limite_inferior = media_amostral - margem_erro
limite_superior = media_amostral + margem_erro

print(f"t crítico: {t_critico:.4f}")
print(f"Erro-padrão: {erro_padrao:.4f}")
print(f"Margem de erro: {margem_erro:.4f}")
print(
    f"IC de 95%: "
    f"[{limite_inferior:.2f}, "
    f"{limite_superior:.2f}]"
)
```

```
t crítico: 1.9842
Erro-padrão: 2.9230
Margem de erro: 5.7999
IC de 95%: [113.48, 125.08]
```

Exercício

- Vamos criar uma amostra controlada de tempos entre chegadas.
- Cada valor representa um tempo, em segundos, entre dois eventos consecutivos.
 - a. Calcule média, mediana e desvio-padrão.
 - b. Construa um histograma e um boxplot.
 - c. Estime a taxa de ocorrência:

$$\hat{\lambda} = \frac{1}{\bar{x}}$$

- d. Compare o histograma com uma densidade exponencial.
- e. Compare a ECDF com a CDF exponencial.
- f. Calcule um intervalo de confiança de 95% para a média.
- g. Registre uma conclusão sobre a adequação do modelo.


```
import numpy as np

rng = np.random.default_rng(42)

tempos = rng.exponential(
    scale=20,
    size=120
)
```

Resumo

- A amostra descreve o que foi observado.
- A distribuição representa um comportamento aleatório possível.
- Os parâmetros precisam ser estimados a partir dos dados.
- Toda estimativa possui incerteza.
- Um modelo útil não precisa reproduzir perfeitamente cada observação.
- A adequação do modelo depende do objetivo da análise.



Prof. Dr. Carlos Melo

<https://calendly.com/prof-casm>

 carlos.melo@upe.br