



Análise Operacional

Modelagem e Simulação - Aula #06

Prof. Dr. Carlos Melo

 carlos.melo@upe.br

O que as medições revelam sobre um sistema?


- Um servidor Web foi observado durante 10 minutos
- Nesse período 30.000 requisições foram concluídas
- A utilização média do processador foi de 90,23%
- A partir dessas duas informações, podemos investigar:
 - Quantas requisições o sistema conclui por segundo
 - Quanto tempo de processador cada requisição demanda
 - Se o processador está próxima da saturação
 - Qual carga adicional o sistema pode receber
- Como transformar essas medições em informações sobre o desempenho do sistema?

Análise operacional

- A análise operacional utiliza dados obtidos de um sistema em funcionamento.
- Esses dados são coletados durante um período finito de observação (T)
- As relações entre as quantidades medidas recebem o nome de leis operacionais
- Uma lei operacional expressa uma relação que deve ser satisfeita pelas medições.
- As principais leis operacionais não exigem uma distribuição específica para:
 - Tempos de serviço (*Service Time*)
 - Intervalos entre chegadas (*Time between arrivals*)
 - Número de solicitações.

Recapitulando

- Antes de medir, precisamos definir:
 - Qual sistema será analisado
 - Quais componentes fazem parte dele
 - Quando a observação começa e termina.
- O período de observação é representado por T
- As solicitações atravessam a fronteira do sistema:
 - Chegadas $\rightarrow$ **Sistema** $\rightarrow$ Conclusões
- Durante sua execução, uma solicitação pode utilizar vários recursos internos.



Quantidades medidas diretamente

Símbolo	Significado
T	Duração do período de observação
$A_{\emptyset}$	Chegadas ao sistema
$C_{\emptyset}$	Conclusões do sistema
A_i	Chegadas ao recurso i
C_i	Conclusões no recurso i
B_i	Tempo em que o recurso i permaneceu ocupado

- O índice $\emptyset$ representa o sistema completo, enquanto o índice i representa um recurso específico (CPU, disco, servidor, etc.)

Equilíbrio

- Durante um período de observação suficientemente longo, esperamos que o número de chegadas seja próximo do número de conclusões:
 - $A_i \approx C_i$
- Podemos medir o desequilíbrio relativo por meio de:
 - $\delta_i = |A_i - C_i|/C_i$
- Em que:
 - A_i : número de chegadas ao recurso i
 - C_i : número de conclusões no recurso i
 - δ_i : diferença relativa entre chegadas e conclusões
- Quando $\delta_i \approx 0$ consideramos que o recurso apresenta equilíbrio de fluxo durante o período observado
- $A_{cpu} = 1800$ e $C_{cpu} = 1800$ então
 - $\delta_{cpu} = |1800 - 1800|/1800 = 0$

Taxa de chegada e vazão

- A taxa de chegada informa quantos trabalhos chegam ao recurso por unidade de tempo:
 - $\lambda_i = A_i/T$
- A vazão informa quantos trabalhos e recurso conclui por unidade de tempo:
 - $X_i = C_i/T$
- Em que:
 - λ_i : taxa de chegada ao recurso i
 - X_i : vazão do recurso i
 - A_i : número de chegadas
 - C_i : número de conclusões
 - T : duração da observação
- Se T estiver em segundos, as unidades podem ser:
 - requisições/s, transações/s ou pacotes/s

Taxa de chegada e vazão do processador

- Considere as medições
 - $T = 60s$
 - $A_{CPU} = 1800$ transações
 - $C_{CPU} = 1800$ transações
- Taxa de chegada:
 - $\lambda_{CPU} = A_{CPU}/T = 1800/60 = 30$ transações/s
- Vazão:
 - $X_{CPU} = C_{CPU}/T = 1800/60 = 30$ transações/s

Utilização do recurso

- A utilização representa a fração do período em que o recurso permaneceu ocupado:
 - $U_i = B_i/T$
- Em que:
 - U_i : utilização do recurso i
 - B_i : tempo ocupado
 - T : duração da observação
- Como o tempo ocupado não pode superar o período observado:
 - $0 \leq U_i \leq 1$
- Para apresentar o resultado como porcentagem:
 - $U_i(\%) = 100 \times U_i$
- Se o processador permaneceu ocupado durante 36s dos 60s observados então:
 - $U_{CPU} = 36/60 = 0,6$
 - $U_{CPU} = 100 \times 0,6 = 60\%$

Tempo médio de serviço

- O tempo médio de serviço representa quanto tempo ocupado o recurso utilizou, em média, para cada trabalho concluído:
 - $S_i = B_i / C_i$
- Em que:
 - S_i : tempo médio de serviço no recurso i
 - B_i : tempo ocupado
 - C_i : quantidade de trabalhos concluídos
- Exemplo:
 - $B_{CPU} = 36s$
 - $C_{CPU} = 1800$ transações
 - $S_{CPU} = B_{CPU} / C_{CPU} = 36 / 1800 = 0,02$ s/transação ou 20ms/transação
- O **tempo de serviço** considera apenas o tempo em que o recurso trabalha na solicitação e **não inclui o tempo de espera na fila**

Medidas básicas e derivadas

- As medidas básicas são obtidas diretamente:
 - T, A_i, C_i, B_i
- As medidas derivadas são calculadas a partir delas
 - λ_i, X_i, U_i, S_i
- Para o processador observado:

Medida	Valor
Período	60s
Chegadas	1800
Conclusões	1800
Tempo ocupado	36s
Taxa de chegada	30 transações/s
Vazão	30 transações/s
Utilização	60%
Tempo de serviço	20ms/transação

Lei da Utilização (*Utilization Law*)

- Sabemos que a utilização é
 - $U_i = B_i/T$
- Multiplicando por C_i/C_i
 - $U_i = B_i/T \times C_i/C_i$
 - $U_i = B_i/C_i \times C_i/T$
- E reorganizando os termos como:
 - $S_i = B_i/C_i$ e $X_i = C_i/T$
- Obtemos a Lei da Utilização:
 - $U_i = S_i \times X_i$
- Onde:
 - U_i : fração do tempo ocupado
 - S_i : tempo de serviço por trabalho
 - X_i : trabalhos concluídos por unidade de tempo

Interpretação da Lei da Utilização

- Para o processador:
 - $S_{CPU} = 20ms/transação$
- Convertamos de volta para segundos:
 - $S_{CPU} = 0,020s/transação$
- A vazão é:
 - $X_{CPU} = 30 \text{ transações/s}$
- Aplicando a lei da utilização
 - $U_{CPU} = S_{CPU} X_{CPU}$
 - $U_{CPU} = 0,02 (s/transação) * 30 (transações/s) = 0,6$
- As unidades se cancelam
 - $U_{CPU} = 0,02 * 30 = 0,6 = 60\%$
- Outras formas da lei:
 - $S_i = U_i / X_i$
 - $X_i = U_i / S_i$

Utilização de um Gateway

- Um gateway processa:
 - $X = 125 \text{ pacotes/s}$
- O tempo médio necessário para encaminhar cada pacote é:
 - $S = 2 \text{ ms/pacote}$
- Primeiro, convertamos milissegundos para segundos:
 - $2 \text{ ms} = 0,002\text{s}$
- Aplicando a Lei da Utilização:
 - $U = SX$
 - $U = 0,002(\text{s/pacote}) \times 125(\text{pacotes/s}) = 0,25 = 25\%$
- O gateway permanece ocupado, em média, durante um quarto do período observado.

Exercício

- Um sistema possui três recursos. As medições produziram os seguintes valores:
- Para cada recurso:
 - Converta o tempo de serviço para segundos
 - Calcule a utilização com $U_i = S_i X_i$
 - Identifique o recurso com maior utilização

Recurso	Tempo de serviço	Vazão
CPU	4 ms/operação	150 operações/s
Disco	8 ms/operação	60 operações/s
Rede	1,5 ms/operação	200 operações/s

Identificação do gargalo pela utilização

- O gargalo é o recurso que limita o crescimento da vazão do sistema
- Considerando a mesma classe de transação e um aumento proporcional da carga, o recurso com maior utilização alcançará a saturação primeiro
- Se o sistema possui K recursos:
 - $U_g = \max\{U_1, U_2, \dots, U_k\}$
- Em que
 - U_g : Utilização do recurso que é gargalo
 - U_i : Utilização do recurso i
 - K : Quantidade de recursos analisados
- No exercício os resultados foram:
 - $U_{CPU} = 60\%$
 - $U_{DISCO} = 48\%$
 - $U_{REDE} = 30\%$
- Portanto, a CPU é o gargalo para a carga observada.

Número médio de visitas

- Uma transação do sistema pode utilizar o mesmo recurso várias vezes.
- O número médio de visitas ao recurso i é:
 - $V_i = C_i / C_\theta$
- Em que:
 - V_i : Número médio de visitas ao recurso i
 - C_i : Operações concluídas pelo recurso i
 - C_θ : Transações concluídas pelo sistema
- Durante o período observado:
 - $C_\theta = 100$ transações
 - $C_{DISCO} = 500$ operações
- Logo
 - $V_{DISCO} = 500 / 100 = 5$ acessos/transação
- Cada transação realizou, em média, cinco visitas ao disco.

Lei do Fluxo Forçado

- A Lei do Fluxo Forçado relaciona a vazão do sistema com a quantidade de trabalho executada por cada recurso.
- A vazão do recurso i é:
 - $X_i = C_i/T$
- Podemos multiplicar a expressão por $C_\theta/C_\theta = 1$:
 - $X_i = C_i/T \times C_\theta/C_\theta$
- Reorganizando como:
 - $X_i = C_i/C_\theta \times C_\theta/T$
- E:
 - $V_i = C_i/C_\theta$
 - $X_\theta = C_\theta/T$
- Obtemos assim a Lei do Fluxo Forçado:
 - $X_i = V_i X_\theta$
 - (vazão do recurso = visitas por transação x vazão do sistema)

Fluxo de acessos ao disco

- Cada transação concluída pelo servidor realiza, em média:
 - $V_{DISCO} = 2 \text{ acessos/transação}$
- A vazão do sistema é:
 - $X_{\theta} = 5,6 \text{ transações/s}$
- Aplicando a Lei do Fluxo Forçado:
 - $X_{DISCO} = V_{DISCO} X_{\theta}$
 - $X_{DISCO} = 2 \text{ (acessos/transação)} \times 5,6 \text{ (transações/s)}$
 - $X_{DISCO} = 11,2 \text{ acessos/s}$

Tempo de serviço e demanda de serviço

- O tempo médio de serviço S_i considera uma única visita ao recurso:
 - S_i = tempo médio por visita
- A demanda de serviço D_i considera todas as visitas realizadas por uma transação:
 - $D_i = V_i S_i$
- Em que:
 - D_i : Demanda média de uma transação sobre o recurso i
 - V_i : Número médio de visitas ao recurso
 - S_i : Tempo médio de serviço em cada visita

Exemplo

- Uma transação realiza cinco acessos ao disco:
 - $V_{DISCO} = 5$
- Cada acesso utiliza o disco durante quatro milissegundos:
 - $S_{DISCO} = 4ms/\text{acesso}$
- Portanto:
 - $D_{DISCO} = 5 \times 4 = 20 \text{ ms/transação}$
- **A demanda de serviço não inclui o tempo de espera na fila.**

Lei da Demanda (*Demand Law*)

- A Lei da Utilização estabelece:
 - $U_i = S_i X_i$
- A Lei do Fluxo Forçado estabelece:
 - $X_i = V_i X_\emptyset$
- Substituindo Xi:
 - $U_i = S_i V_i X_\emptyset$
- Como a demanda de serviço é:
 - $D_i = S_i V_i$
- Obtemos a Lei da Demanda:
 - $U_i = D_i X_\emptyset$
- Também podemos calcular a demanda por:
 - $D_i = U_i / X_\emptyset$
- Em que:
 - D_i : Demanda de serviço da transação no recurso i
 - U_i : Utilização do recurso i
 - $X_\emptyset$: Vazão do sistema

Demanda de CPU de uma requisição Web

- Um servidor Web foi observado durante:
 - $T = 10$ minutos = $600s$
- Nesse período, o sistema concluiu:
 - $C_0 = 30.000$ requisições
- A utilização média da CPU foi:
 - $U_{CPU} = 90,2348\% = 0,902348$
- A vazão do sistema pode ser obtida
 - $X_0 = C_0/T = 30.000/600 = 50$ requisições/s
- A demanda de CPU será:
 - $D_{CPU} = U_{CPU}/X_0$
 - $D_{CPU} = 0,902348/50 = 0,018047$ s/requisição
 - $D_{CPU} \approx 18,047$ ms/requisição

Demanda de serviço em vários recursos

- Um sistema com cinco servidores foi observado durante quatro horas:

- $T = 14400s$

- O sistema concluiu

- $C_0 = 28978$ transações

- A vazão foi:

- $X_0 = 28978/14400 = 2,0124$ transações/s

- Aplicando

- $D_i = U_i/X_0$

- Obtemos:

Recurso	Utilização U_i	Demanda D_i
Servidor 1	39,96%	0,1986 s/transação
Servidor 2	23,89%	0,1187 s/transação
Servidor 3	27,74%	0,1378 s/transação
Servidor 4	52,53%	0,2610 s/transação
Servidor 5	25,98%	0,1291 s/transação

- Qual servidor tem a maior demanda?

Previsão da utilização com uma nova carga

- Considere que o sistema precise concluir 60.000 transações nas mesmas quatro horas:
- $X'_\theta = 60.000/14400 = 4,1667$ transações/s
- Se as demandas permanecerem constantes:
 - $U'_i = D_i X'_\theta$
- Para o Servidor 4:
 - $U'_4 = 0,2610s \times 4,1667 = 1,0875$
 - $U'_4 = 108,75\%$
- Essa utilização supera Servidor 4.

Recurso	Demanda D_i	Utilização necessária U'_i
Servidor 1	0,1986s	82,75%
Servidor 2	0,1187s	49,46%
Servidor 3	0,1378s	57,42%
Servidor 4	0,2610s	108,75%
Servidor 5	0,1291s	53,79%

Limite de vazão imposto pelo gargalo

- Pela Lei da Demanda:
 - $U_i = D_i X_\emptyset$
- Como nenhum recurso pode apresentar utilização superior a 1:
 - $D_i X_\emptyset \leq 1$
- Portanto:
 - $X_\emptyset \leq 1/D_i$
- O recurso com maior demanda estabelece o menor limite
 - $X_{\max} = 1/D_{\max}$
- Para o Servidor 4:
 - $D_{\max} = 0,2610$ s/transação
 - $X_{\max} = 1/0,2610 \approx 3,83$ transações/s
- Se desejarmos limitar a utilização do gargalo a 80%
 - $X_{80\%} = 0,80/0,2610 \approx 3,07$ transações/s
- Ou seja:
 - 3,83 transações/s é o limite teórico associado à saturação
 - 3,07 transações/s mantém o gargalo próximo de 80%
 - A meta de 4,1667 transações/s ultrapassa o limite calculado

Lei de Little

- A Lei de Little relaciona três variáveis operacionais:
 - $N = \lambda R$
- Em que:
 - N : Número médio de itens dentro do sistema
 - λ : Taxa efetiva de chegada
 - R : Tem médio de resposta ou permanência no sistema
- Em um sistema com fluxo equilibrado (balanceado):
 - $\lambda \approx X_{\theta}$
- Portanto, também podemos escrever:
 - $N = X_{\theta} R$
- Outras formas da lei:
 - $R = N/X_{\theta}$
 - $X_{\theta} = N/R$
- Detalhe:
 - transações/s x s/transação = transações

Tempo de permanência em um banco

- Uma fila bancária foi observada durante oito horas:
 - $T = 8 \times 60 = 480$
- Nesse período, chegaram:
 - $A_0 = 324$ clientes
- A taxa de chegada foi:
 - $\lambda = A_0/T = 324/480 = 0,675$ cliente/minuto
- A contagem periódica dos clientes produziu:
 - $N = 11,25$ clientes
- Pela Lei de Little:
 - $R = N/\lambda$
 - $R = 11,25/0,675 = 16,67$ minutos
- Cada cliente permaneceu no sistema, em média, durante:
 - $R = 16,67$ minutos

Espera e atendimento

- Podemos observar duas populações diferentes:
 - N_q = Número médio de clientes esperando
 - N = Número médio de clientes no sistema
- Aplicando a Lei de Little:
 - $N_q = \lambda W$
 - $N = \lambda R$
- Em que:
 - W : Tempo médio de espera na fila
 - R : Tempo médio total no sistema
 - S : Tempo médio de atendimento
- Para um único estágio de atendimento:
 - $R = W + S$

Exemplo

- Em outro período de observação:
 - $\lambda = 0,25$ cliente/minuto
 - $N_q = 11,5$
 - $N = 14,25$
- Logo:
 - $R = 14,25/0,25 = 57$ minutos
 - $W = 11,5/0,25 = 46$ minutos
 - $S = R - w = 57 - 46 = 11$ minutos (Tempo médio de atendimento)

Lei Geral do Tempo de Resposta

- Uma transação pode passar por vários recursos antes de deixar o sistema.
- O tempo médio de resposta é:

$$R = \sum_{i=1}^R V_i R_i$$

- Em que:
 - R : Tempo médio de resposta do sistema
 - k : Quantidade de recursos
 - V_i : Número médio de visitas ao recurso i
 - R_i : Tempo médio de permanência em cada visita ao recurso i
- O tempo R_i inclui:
 - $R_i = W_i + S_i$
- Portanto:

$$R = \sum_{i=1}^k V_i (W_i + S_i)$$

Tempo de resposta de uma aplicação

- Uma requisição utiliza três recursos:

Recurso	Visitas V_i	Tempo por visita R_i	Contribuição $V_i R_i$
Autenticação	1	20ms	20ms
Banco de Dados	2	35ms	70ms
Disco	0,5*	80ms	40ms

- Aplicando:

$$R = \sum_{i=1}^3 V_i R_i$$

- $R = 1 \times 20 + 2 \times 35 + 0,5 \times 80 = 130\text{ms}$
 - *0,5 visitas ao disco implica que nem toda requisição precisa de acesso ao disco, apenas uma a cada 2.*

Lei do Tempo de Resposta Interativo


- Em um sistema interativo, cada usuário repete um ciclo:
 - Envia uma solicitação
 - Espera a resposta do sistema
 - Interage com o resultado
 - Envia a próxima solicitação
- A duração média desse ciclo é: $R + Z$
- Em que:
 - R : Tempo médio de resposta do sistema
 - Z : Tempo médio de interação do usuário
 - N : Número de usuários ativos
 - X_θ : Vazão do sistema
- Cada usuário produz, em média $1/(R+Z)$ solicitações por unidade de tempo
- Para N usuários: $X_\theta = N/(R+Z)$
- Também podemos calcular o tempo de resposta: $R = (N/X_\theta) - Z$

Sistema Interativo

- Um portal possui:
 - $N = 120$ usuários ativos
- Cada usuário leva, em média $Z = 15s$ entre o recebimento de uma resposta e o envio da próxima solicitação
- A vazão medida é $X_\theta = 6$ solicitações/s.
- Aplicando $R = (N/X_\theta) - Z$:
 - $R = (120/6) - 15 = 20 - 15 = 5s$
- Verificação inversa:
 - $X_\theta = 120/(5+15) = 6$ solicitações/s

Síntese da Análise Operacional

Relação	Lei Operacional	O que permite calcular
$U_i = S_i X_i$	Lei da Utilização	Utilização, serviço ou vazão do recurso
$X_i = V_i X_\theta$	Lei do Fluxo Forçado	Fluxo de trabalho
$U_i = D_i X_\theta$	Lei da Demanda	Demanda ou utilização do recurso
$N = X_\theta R$	Lei de Little	População, vazão ou tempo de resposta
$X_\theta = N/(R+Z)$	Lei do Tempo de Resposta Interativo	Comportamento de sistemas com usuários ativos



Prof. Dr. Carlos Melo

<https://calendly.com/prof-casm>

 carlos.melo@upe.br